

▼

📄 Memoria de prácticas de Fundamentos de los Sistemas Inteligentes

Alejandro Medina Díaz & Aitor Ventura Delgado

Curso 2020/2021 - Escuela de Ingeniería Informática

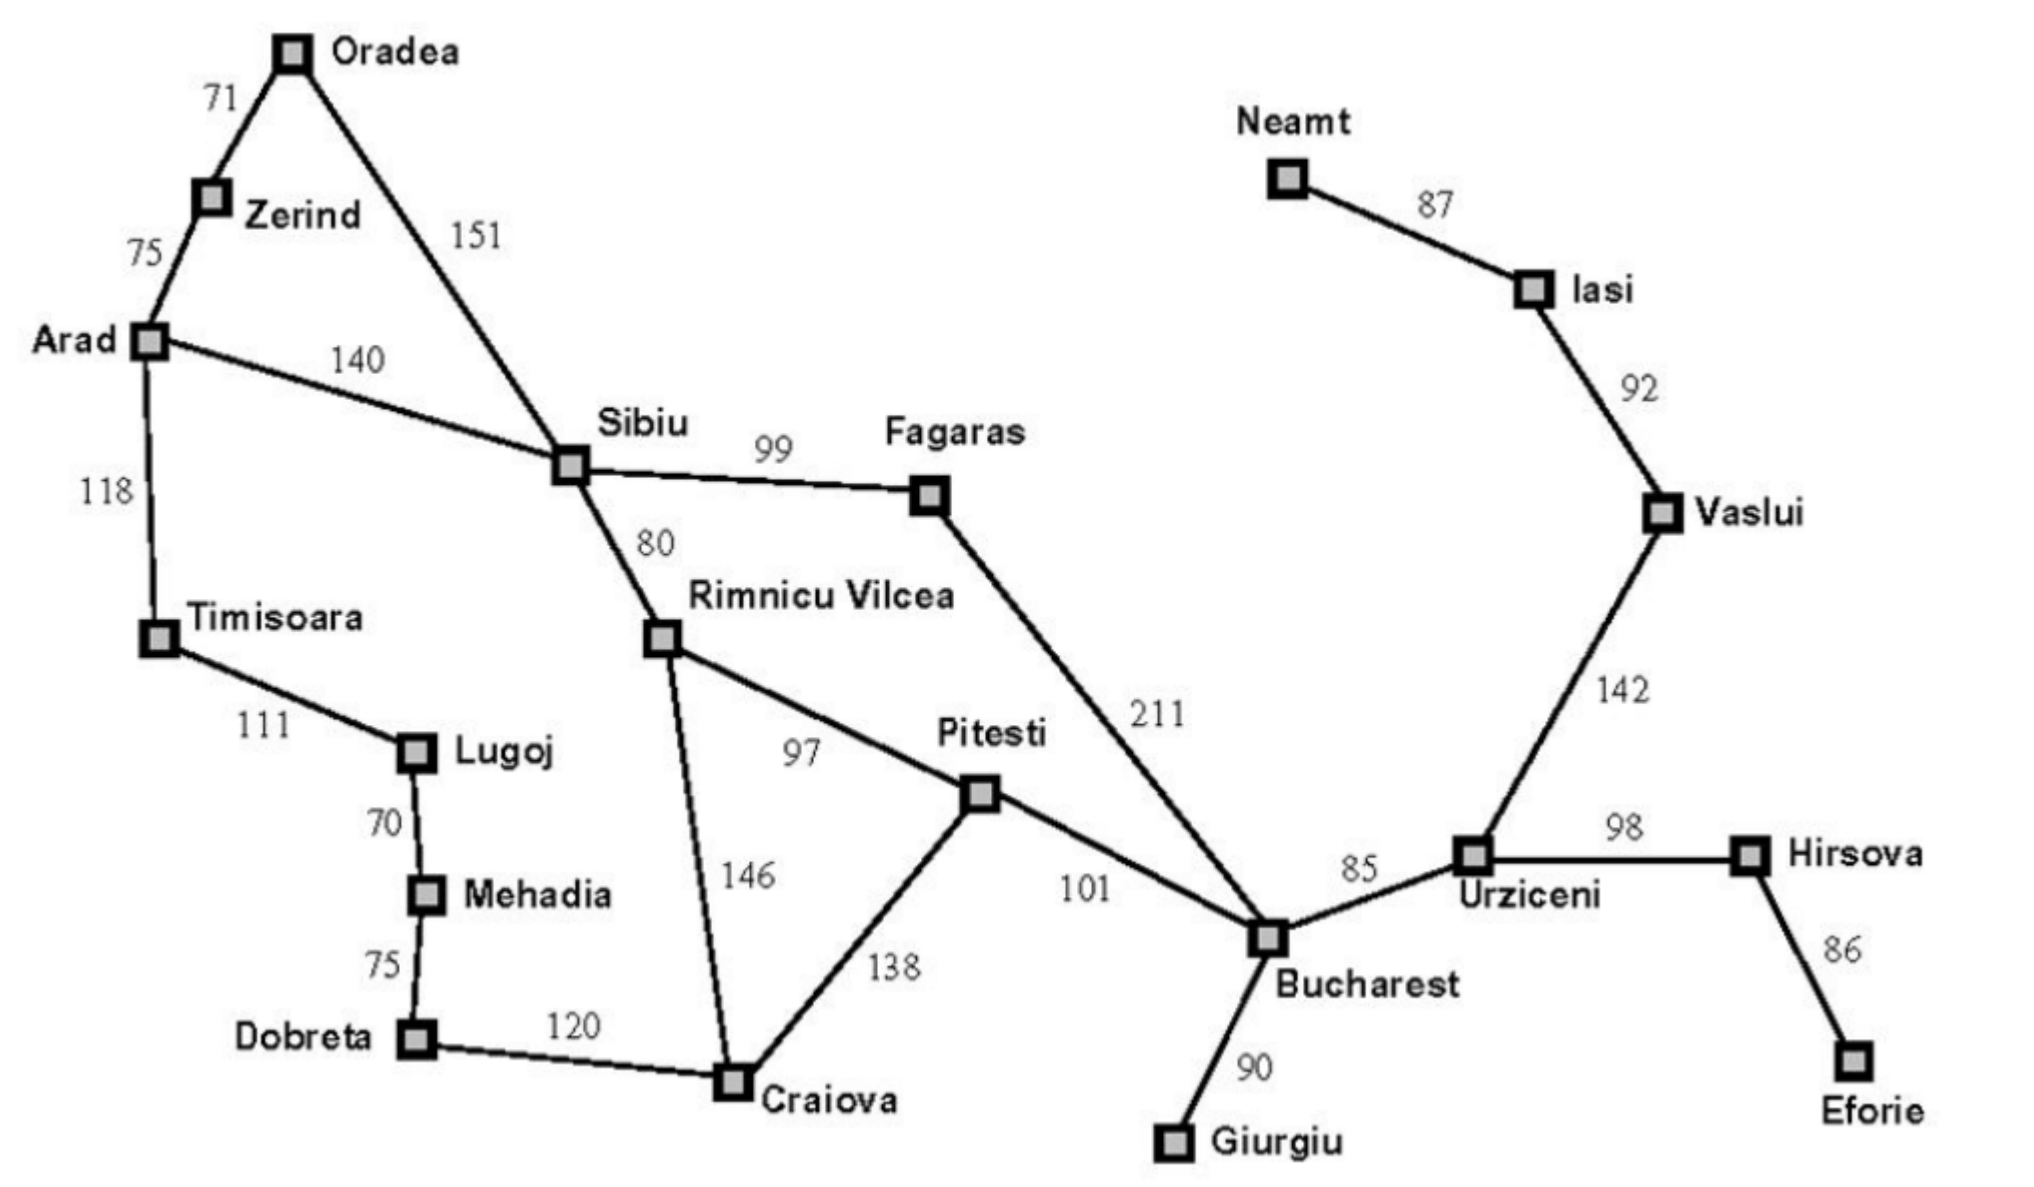
¿Quiénes somos?

Somos el **equipo 06** de prácticas de la asignatura **40825 - Fundamentos de los Sistemas Inteligentes** del curso 2020/2021 de la Escuela de Ingeniería Informática, en la Universidad de Las Palmas de Gran Canaria.

Las prácticas de este año han sido dos: la primera, que se centra en encontrar y desarrollar diferentes estrategias de búsqueda en grafos; y la segunda, que pide desarrollar una red neuronal para la clasificación de un conjunto de imágenes.

▼

🔍 Primera práctica - Búsqueda en grafos.



► Código base

```
[ ] 1, 3 celdas ocultas
```

▼

Primera parte

La estrategia de búsqueda de ramificación y acotación pertenece a las estrategias de búsqueda no informada. Su principio de funcionamiento se basa en ordenar la lista abierta tomando como criterio el coste acumulado de cada trayectoria parcial, representada ésta por cada nodo de la lista abierta. Por tanto, el primer nodo de la lista irá expandiéndose y generando nuevas trayectorias por ramificación de sus hijos.

Tareas:

- A partir del código base entregado, se deberá programar el método de ramificación y acotación. Utilícese como problema el grafo de las ciudades de Rumanía presente en el código.
- Comparar la cantidad de nodos expandidos por este método con relación a los métodos de búsqueda primero en anchura y primero en profundidad.
- Realizar a mano la traza de una búsqueda (opcional).

▼

Realización de los alumnos

Decidimos crear un nuevo tipo de cola, que se llamaría *OrderedQueue*. Esta cola devuelve los elementos en orden creciente dependiendo de los *path_cost* de los nodos. Luego, para la búsqueda de ramificación y acotación, llamamos al método *graph_search* con esta cola.

```
1 class OrderedQueue(Queue):
2     """A queue that pops its elements in order of least cost."""
3
4     def __init__(self):
5         self.A = []
6         self.dirty = False
7
8     def append(self, item):
9         self.A.append(item)
10        self.dirty = True
11
12    def __len__(self):
13        return len(self.A)
14
15    def extend(self, items):
16        self.A.extend(items)
17        self.dirty = True
18
19    def pop(self):
20        if self.dirty:
21            self.A = sorted(self.A, key=lambda node: node.path_cost, reverse=True)
22
23        self.dirty = False
24
25        return self.A.pop()
```

```
1 def branch_and_bound_search (problem):
2     """Search using least cost node in the fringe """
3     return graph_search(problem, OrderedQueue())

1 print(branch_and_bound_search(ab).path())

[<Node B>, <Node P>, <Node R>, <Node S>, <Node A>]
```

▼ Segunda parte

La estrategia de búsqueda ramificación y acotación con subestimación pertenece a las estrategias de búsqueda informada. En este caso, además de utilizar el coste acumulado de un camino desde el estado inicial hasta un cierto estado del grafo, se utiliza una estimación heurística hasta el estado final para ordenar la lista abierta. De esta forma, dado un determinado nodo n del árbol de búsqueda, la expresión de coste estimado $f(n)$ será:

$$f(n) = g(n) + h(n)$$

Donde $g(n)$ representa el coste acumulado y $h(n)$ la heurística utilizada. Para que el camino encontrado sea óptimo, la heurística debe ser consistente. Es decir, ha de cumplir que para cada nodo n y cada nodo hijo n' alcanzado mediante la acción a , el valor heurístico $h(n)$ debe ser siempre menor o igual al valor heurístico $h(n')$ más el coste del nodo n al n' mediante la acción a .

$$h(n) \leq c(n, a, n') + h(n')$$

Tareas:

- A partir del código base entregado, se deberá programar el método de búsqueda de ramificación y acotación con subestimación. Utilícese como problema el grafo de las ciudades de Rumanía presente en el código. Como heurística se utilizará la distancia en línea recta entre cada estado y el estado final.
- Comparar la cantidad de nodos expandidos por este método con relación al método de ramificación y acotación.
- Demostrar con un ejemplo hecho a mano que si la heurística no fuera consistente no se aseguraría el carácter óptimo de la búsqueda (opcional).

▼ Realización de los alumnos

Decidimos modificar la cola previamente creada, *OrderedQueue*, cuyo cambio fue que decidimos ordenar la lista según insertáramos los elementos, en vez de a la hora de sacarlos. Además, añadimos un parámetro λ (f), que define nuestra función heurística.

```
1 class OrderedQueue(Queue):
2     """A queue that pops its elements in order of least cost using heuristics."""
3
4     def __init__(self, f=lambda x: 0):
5         self.A = []
6         self.f = f
7
8     def append(self, item):
9         bisect.insort(self.A, (item.path_cost + self.f(item), item))
10
11     def __len__(self):
12         return len(self.A)
13
14     def pop(self):
15         return self.A.pop(0)[1]
```

Luego, en el apartado de búsquedas, editamos la clase *Node*, en concreto el método *path*, para mostrar el coste acumulado, y desarrollamos el método *less than*, que compara dos nodos por su estado. Este último nos servirá para desambiguar los casos de empate en nuestra cola por orden alfabético. Modificamos el método *graph_search* para mostrar los nodos visitados, y desarrollamos los métodos *branch_and_bound_search* y *best_first_graph_search*. Ambas utilizarían esta nueva cola que habíamos desarrollado previamente.

```
1 class Node:
2     """A node in a search tree. Contains a pointer to the parent (the node
3     that this is a successor of) and to the actual state for this node. Note
4     that if a state is arrived at by two paths, then there are two nodes with
5     the same state. Also includes the action that got us to this state, and
6     the total path_cost (also known as g) to reach the node. Other functions
7     may add an f and h value; see best_first_graph_search and astar_search for
8     an explanation of how the f and h values are handled. You will not need to
9     subclass this class."""
10
11     def __init__(self, state, parent=None, action=None, path_cost=0):
12         """Create a search tree Node, derived from a parent by an action."""
13         update(self, state=state, parent=parent, action=action,
14               path_cost=path_cost, depth=0)
15         if parent:
16             self.depth = parent.depth + 1
17
18     def __repr__(self):
19         return "<Node %s(%s)>" % (self.state,self.path_cost)
20
21     def __lt__(self, other):
22         return self.state < other.state
23
24     def path(self):
25         """Create a list of nodes from the root to this node."""
26         x, result = self, [self]
27         while x.parent:
28             result.append(x.parent)
29             x = x.parent
30         return result
31
32     def expand(self, problem):
33         """Return a list of nodes reachable from this node. [Fig. 3.8]"""
34         return [Node(next, self, act,
35                     problem.path_cost(self.path_cost, self.state, act, next))
36               for (act, next) in problem.successor(self.state)]
37
38
39 # _____
40 ## Uninformed Search algorithms
41
```

```
42 def graph_search(problem, fringe):
43     """Search through the successors of a problem to find a goal.
44     The argument fringe should be an empty queue.
45     If two paths reach a state, only use the best one. [Fig. 3.18]"""
46     closed = {}
47     stats = {}
48     stats["visited"] = 0
49     fringe.append(Node(problem.initial))
50     while fringe:
51         node = fringe.pop()
52         stats["visited"] += 1
53         if problem.goal_test(node.state):
54             return (node, stats)
55         if node.state not in closed:
56             closed[node.state] = True
57             fringe.extend(node.expand(problem))
58     return (None, stats)
59
60
61 def breadth_first_graph_search(problem):
62     """Search the shallowest nodes in the search tree first. [p 74]"""
63     return graph_search(problem, FIFOQueue()) # FIFOQueue -> fringe
64
65
66 def depth_first_graph_search(problem):
67     """Search the deepest nodes in the search tree first. [p 74]"""
68     return graph_search(problem, Stack())
69
70 def branch_and_bound_search (problem):
71     """Search using least cost node in the fringe """
72     return graph_search(problem, OrderedQueue())
73
74 ## Informed Search Algorithms
75 def branch_and_bound_heuristic_search(problem):
76     return graph_search(problem, OrderedQueue(problem.h))
```

Y finalmente lo llamábamos en run.py, habiéndonos desarrollado el método visualizar para mostrar por pantalla el coste acumulado hasta el momento, así como los nodos visitados. Además, parametrizamos los nodos inicio y final, para interactuar de forma dinámica con el programa.

```
1 inicio = 'A' #@param ['A', 'B','C', 'D','E','F','G','H','I', 'L','N','O','P','R','S','T'.
2 fin     = 'B' #@param ['A', 'B','C', 'D','E','F','G','H','I', 'L','N','O','P','R','S','T'.
3
4 ab = GPSProblem(inicio, fin, romania)
5
6 def visualizar(a, name):
7     print(name+"\t", a[1], "\t", a[0].path())
8
9 visualizar(breadth_first_graph_search(ab), "# Breadth First " + inicio + fin + "\t")
10 visualizar(depth_first_graph_search(ab), "# Depth First " + inicio + fin + "\t")
11 visualizar(branch_and_bound_search(ab), "# Branch and Bound " + inicio + fin + "\t")
12 visualizar(branch_and_bound_heuristic_search(ab), "# Branch and Bound H " + inicio + fin

```

inicio: A

fin: B

```

# Breadth First AB      {'visited': 16}      [<Node B(450)>, <Node F(239)>, <Node S(140)>, <Node A(0)>]
# Depth First AB       {'visited': 10}      [<Node B(733)>, <Node P(632)>, <Node C(494)>, <Node D(374)>, <Node M(299)>, <Node L(229)>, <Node T(118)>, <Node A(0)>]
# Branch and Bound AB  {'visited': 24}      [<Node B(418)>, <Node P(317)>, <Node R(220)>, <Node S(140)>, <Node A(0)>]
# Branch and Bound H AB {'visited': 6}       [<Node B(418)>, <Node P(317)>, <Node R(220)>, <Node S(140)>, <Node A(0)>]
```

🌀 Segunda práctica - Redes neuronales.

Se pide desarrollar una red neuronal para la clasificación de un conjunto de imágenes. Este conjunto puede ser creado por el propio alumno hacinedo fotos de diferentes objetos en diferentes localizaciones y condiciones. Por ejemplo, libros, cubiertos de cocina, monedas, prendas de ropa... rollos de papel higiénico o lo que se tercié. El número recomendable de clases distintas será entre 4 y 7. Cada clase deberá tener un mínimo de 20 imágenes (cuantas más, mejor) para el conjunto de entrenamiento y 5 para el conjunto de validación. Una vez creado el dataset haremos lo siguiente:

- Entrenar la red y visualizar gráficamente el progreso del accuracy tanto del conjunto de entrenamiento como del conjunto de validación. Para ello, se puede hacer uso del objeto history que devuelve el método fit_generator del modelo.
- Hacer data augmentation sobre el conjunto de entrenamiento.
- Probar con distintas configuraciones de hiperparámetros para escoger la que mejor resultados ofrezca.
- Categorical cross entropy es una función de pérdida similar a la ya estudiada suma de diferencias al cuadrado. Explica cómo y por qué funciona esta función de pérdida.

Condiciones de la entrega:

- La práctica se hará en grupo, de dos alumnos. No se permiten los grupos de tres o más alumnos. Tampoco se permitirá su realización de forma individual.
- Los resultados deberán presentarse contenidos en una memoria en PDF (no otro formato).
- El código y su funcionamiento se presentarán en una defensa por videoconferencia. Para ello será imprescindible activar la cámara del ordenador o, en su defecto, cámara del móvil. También será obligatorio mostrar el DNI.
- En cuanto al procedimiento de entrega y plazos para las defensas, se comunicarán más adelante.

➤ Realización de los alumnos

➤ Establecimiento del entorno

En esta parte nos encargamos de establecer la conexión con Google Drive y cargar los datos en la máquina virtual. Además, definimos las funciones que utilizaremos más adelante para guardar los resultados de las diferentes pruebas. Creamos el fichero *parameters.json* en caso de que no exista, con el contenido apropiado, y si existe lo notificamos.

```
1 from google.colab import drive
2 drive.mount('/content/gdrive')
3
4 #@markdown ##Conectar a Google Drive { display-mode: "both" }
5 #@markdown Este trozo de código nos permite conectar nuestro drive, de donde sacaremos 1:
6 #@markdown Ejecutar siempre que empecemos una sesión.
```

Mounted at /content/gdrive

Conectar a Google Drive

Este trozo de código nos permite conectar nuestro drive, de donde sacaremos la información de los datasets y guardaremos el estado de nuestros modelos. Ejecutar siempre que empecemos una sesión.

▼ Descargar DataSet

Esta parte del código determina la ruta en GDrive hasta el comprimido del DataSet. El ficheor se descargará y su contenido estará disponible en

[/content/datasets/uncompressed](#)

```
1  #@markdown ##Descargar Dataset
2  #@markdown Determina la ruta en GDrive hasta el comprimido de tu dataset:
3  datasetZip_path = "/ColabNotebooks/datasets/DogDataset.zip" #@param {type:"string"}
4  models_path = "/ColabNotebooks/models" #@param {type:"string"}
5  #@markdown El fichero se descargará y su contenido estará disponible en `/content/dataset
6
7  #creamos carpetas si no estan
8  !mkdir /content/datasets
9  !mkdir ./datasets/compressed
10 !mkdir ./datasets/uncompressed
11
12 drive_ds_zip = "gdrive/MyDrive"+datasetZip_path
13 #drive_mod_dir = "gdrive/MyDrive"+models_path
14
15 #traemos el dataset alojado en drive a la maquina virtual y lo expandimos
16 !rsync -ah --progress $drive_ds_zip datasets/compressed/ds.zip
17 #descomprimimos
18 !unzip ./datasets/compressed/ds.zip -d ./datasets/uncompressed
19
```

```

sending incremental file list
DogDataset.zip
   54.62M 100%  21.45MB/s   0:00:02 (xfr#1, to-chk=0/1)
Archive:  ./datasets/compressed/ds.zip
  creating: ./datasets/uncompressed/test/
  creating: ./datasets/uncompressed/test/n02088364-beagle/
  inflating: ./datasets/uncompressed/test/n02088364-beagle/n02088364_15315.jpg
  inflating: ./datasets/uncompressed/test/n02088364-beagle/n02088364_15370.jpg
  inflating: ./datasets/uncompressed/test/n02088364-beagle/n02088364_15690.jpg
  inflating: ./datasets/uncompressed/test/n02088364-beagle/n02088364_15787.jpg
  inflating: ./datasets/uncompressed/test/n02088364-beagle/n02088364_15877.jpg
  inflating: ./datasets/uncompressed/test/n02088364-beagle/n02088364_16060.jpg
  inflating: ./datasets/uncompressed/test/n02088364-beagle/n02088364_16065.jpg
  inflating: ./datasets/uncompressed/test/n02088364-beagle/n02088364_16165.jpg
  inflating: ./datasets/uncompressed/test/n02088364-beagle/n02088364_16207.jpg
  inflating: ./datasets/uncompressed/test/n02088364-beagle/n02088364_16210.jpg
  inflating: ./datasets/uncompressed/test/n02088364-beagle/n02088364_16339.jpg
  inflating: ./datasets/uncompressed/test/n02088364-beagle/n02088364_16493.jpg
  inflating: ./datasets/uncompressed/test/n02088364-beagle/n02088364_16502.jpg
  inflating: ./datasets/uncompressed/test/n02088364-beagle/n02088364_16508.jpg
  inflating: ./datasets/uncompressed/test/n02088364-beagle/n02088364_16519.jpg
  inflating: ./datasets/uncompressed/test/n02088364-beagle/n02088364_16588.jpg
  inflating: ./datasets/uncompressed/test/n02088364-beagle/n02088364_16635.jpg
  inflating: ./datasets/uncompressed/test/n02088364-beagle/n02088364_16689.jpg
  inflating: ./datasets/uncompressed/test/n02088364-beagle/n02088364_16695.jpg
  inflating: ./datasets/uncompressed/test/n02088364-beagle/n02088364_16704.jpg
  inflating: ./datasets/uncompressed/test/n02088364-beagle/n02088364_16721.jpg
  inflating: ./datasets/uncompressed/test/n02088364-beagle/n02088364_16791.jpg
  inflating: ./datasets/uncompressed/test/n02088364-beagle/n02088364_16881.jpg
  inflating: ./datasets/uncompressed/test/n02088364-beagle/n02088364_16985.jpg
  inflating: ./datasets/uncompressed/test/n02088364-beagle/n02088364_17167.jpg
  inflating: ./datasets/uncompressed/test/n02088364-beagle/n02088364_17170.jpg
  inflating: ./datasets/uncompressed/test/n02088364-beagle/n02088364_17258.jpg
  inflating: ./datasets/uncompressed/test/n02088364-beagle/n02088364_17294.jpg
  inflating: ./datasets/uncompressed/test/n02088364-beagle/n02088364_17314.jpg
  inflating: ./datasets/uncompressed/test/n02088364-beagle/n02088364_17406.jpg
  inflating: ./datasets/uncompressed/test/n02088364-beagle/n02088364_17473.jpg
  inflating: ./datasets/uncompressed/test/n02088364-beagle/n02088364_17474.jpg
  inflating: ./datasets/uncompressed/test/n02088364-beagle/n02088364_17479.jpg
  inflating: ./datasets/uncompressed/test/n02088364-beagle/n02088364_17530.jpg
  inflating: ./datasets/uncompressed/test/n02088364-beagle/n02088364_17534.jpg
  inflating: ./datasets/uncompressed/test/n02088364-beagle/n02088364_17553.jpg
  inflating: ./datasets/uncompressed/test/n02088364-beagle/n02088364_17671.jpg
  inflating: ./datasets/uncompressed/test/n02088364-beagle/n02088364_17689.jpg
  inflating: ./datasets/uncompressed/test/n02088364-beagle/n02088364_17766.jpg
  inflating: ./datasets/uncompressed/test/n02088364-beagle/n02088364_17935.jpg
  inflating: ./datasets/uncompressed/test/n02088364-beagle/n02088364_18403.jpg
  creating: ./datasets/uncompressed/test/n02094433-Yorkshire_terrier/
  inflating: ./datasets/uncompressed/test/n02094433-Yorkshire_terrier/n02094433_4181.jpg
  inflating: ./datasets/uncompressed/test/n02094433-Yorkshire_terrier/n02094433_4198.jpg
  inflating: ./datasets/uncompressed/test/n02094433-Yorkshire_terrier/n02094433_4214.jpg
  inflating: ./datasets/uncompressed/test/n02094433-Yorkshire_terrier/n02094433_4248.jpg
  inflating: ./datasets/uncompressed/test/n02094433-Yorkshire_terrier/n02094433_4399.jpg
  inflating: ./datasets/uncompressed/test/n02094433-Yorkshire_terrier/n02094433_4588.jpg
  inflating: ./datasets/uncompressed/test/n02094433-Yorkshire_terrier/n02094433_4624.jpg
  inflating: ./datasets/uncompressed/test/n02094433-Yorkshire_terrier/n02094433_4710.jpg
  inflating: ./datasets/uncompressed/test/n02094433-Yorkshire_terrier/n02094433_4916.jpg
  inflating: ./datasets/uncompressed/test/n02094433-Yorkshire_terrier/n02094433_4990.jpg
  inflating: ./datasets/uncompressed/test/n02094433-Yorkshire_terrier/n02094433_5155.jpg
  inflating: ./datasets/uncompressed/test/n02094433-Yorkshire_terrier/n02094433_5176.jpg
```

▼ Funciones de persistencia de modelos

Funciones útiles para guardar y cargar los datos de los modelos. Necesario antes de cualquiera de las siguientes celdas.

```
1  import json
2  import datetime;
3
4  #@markdown ##Funciones de persistencia de modelos
5  #@markdown Funciones útiles para guardar y cargar los datos de los modelos. Necesario antes de cualquiera de las siguientes celdas
6  route_parameters_json = 'gdrive/MyDrive/ColabNotebooks/models/parameters.json' #@param
7  route = 'gdrive/MyDrive/ColabNotebooks/models/' #@param
8
9  import os.path
10 if os.path.isfile(route_parameters_json):
11     print ("File exists")
12 else:
13     initial_data = {}
14     initial_data['modelName'] = []
15     initial_data['modelTrainingData'] = {}
16     with open(route_parameters_json, 'w') as outfile:
17         json.dump(initial_data, outfile)
18     with open(route_parameters_json) as json_file:
19         print(json.load(json_file))
20
21 def load_configuration_json():
22     with open(route_parameters_json) as json_file:
23         return json.load(json_file)
24
25 def save_modelname_to_json(name):
26     with open(route_parameters_json) as json_file:
27         data = json.load(json_file)
28         modelNames = data['modelName']
29         if name not in modelNames:
30             modelNames.append(name)
```


Descargar Dataset

Determina la ruta en GDrive hasta el comprimido de tu dataset:

```
datasetZip_path:  "/ColabNotebooks/datasets/DogDataset.zip"

models_path:      "/ColabNotebooks/models"
```

El fichero se descargará y su contenido estará disponible en `/content/datasets/uncompressed`



```
31     data['modelTrainingData'][name] = history_initial_data()
32     print (data)
33     with open(route_parameters_json, 'w') as outfile:
34         json.dump(data, outfile)
35
36 def history_initial_data():
37     history={}
38     history['accuracy']=[]
39     history['loss']=[]
40     history['val_accuracy']=[]
41     history['val_loss']=[]
42     data={}
43     data['history']= history
44     data['epochs']=0
45     return data
46
47 def save_model(model_storage,model ):
48     ct = datetime.datetime.now().strftime("_%Y%m%d_%H%M%S")
49     model.save(model_storage + model.name + ct )
50     save_modelname_to_json(model.name)
51
52 def load_models(tf):
53     conf = load_configuration_json()
54     loaded_models={}
55     for model in conf['modelNames']:
56         model_route = route + model +""
57         model_versions = !ls $model_route -d
58         loaded_models[model] = tf.keras.models.load_model(model_versions[-1])
59     return loaded_models, conf
60
61 def save_config_to_json(data):
62     with open(route_parameters_json, 'w') as outfile:
63         json.dump(data, outfile)
64
65 print("Ultima ejecuci3n: "+ datetime.datetime.now().strftime("%Y%m%d_%H%M%S"))

```

File exists
Ultima ejecuci3n: 20210602_102247

▼ Definici3n de modelos

En cada celda de este apartado se define un modelo en cada caso, con hiperparámetros diferentes. Los modelos son guardados en el Drive, en un estado inicial sin entrenamiento. En la fase de entrenamiento, cargaremos estos modelos desde el Drive y, tras entrenarlos, se guardará una versi3n entrenada de cada uno de ellos.

```
1  %tensorflow_version 2.x
2  import tensorflow as tf
3  import keras
4  #@markdown ##Nombra el Modelo actual
5  model_name = "Modelo001-Papafrita" #@param
6  model_storage = route
7  with tf.device('/device:GPU:0'):
8      model = tf.keras.models.Sequential(name=model_name)
9      model.add(tf.keras.layers.Conv2D(32, kernel_size=(3, 3),
10                                     activation='relu',
11                                     input_shape=(150, 150, 3)))
12      model.add(tf.keras.layers.MaxPooling2D(pool_size=(3, 3)))
13      model.add(tf.keras.layers.Conv2D(64, (5, 5), activation='relu'))
14      model.add(tf.keras.layers.MaxPooling2D(pool_size=(3, 3)))
15      model.add(tf.keras.layers.Conv2D(64, (3, 3), activation='relu'))
16      model.add(tf.keras.layers.MaxPooling2D(pool_size=(2, 2)))
17      model.add(tf.keras.layers.Dropout(0.25))
18      model.add(tf.keras.layers.Flatten())
19      model.add(tf.keras.layers.Dense(128, activation='relu'))
20      model.add(tf.keras.layers.Dropout(0.5))
21      model.add(tf.keras.layers.Dense(9, activation='softmax'))
22
23      model.compile(loss=keras.losses.categorical_crossentropy,
24                  optimizer=keras.optimizers.Adadelta(),
25                  metrics=['accuracy'])
26      model.build( input_shape =(150, 150, 3))
27
28      model.summary()
29
30      save_model(model_storage, model)

```

Model: "Modelo001-Papafrita"

Layer (type)	Output Shape	Param #
=====		
conv2d_15 (Conv2D)	(None, 148, 148, 32)	896
max_pooling2d_15 (MaxPooling)	(None, 49, 49, 32)	0
conv2d_16 (Conv2D)	(None, 45, 45, 64)	51264
max_pooling2d_16 (MaxPooling)	(None, 15, 15, 64)	0
conv2d_17 (Conv2D)	(None, 13, 13, 64)	36928
max_pooling2d_17 (MaxPooling)	(None, 6, 6, 64)	0
dropout_12 (Dropout)	(None, 6, 6, 64)	0
flatten_6 (Flatten)	(None, 2304)	0
dense_12 (Dense)	(None, 128)	295040
dropout_13 (Dropout)	(None, 128)	0
dense_13 (Dense)	(None, 9)	1161
=====		
Total params: 385,289		
Trainable params: 385,289		
Non-trainable params: 0		

INFO:tensorflow:Assets written to: gdrive/MyDrive/Colab Notebooks/models/Modelo001-Papafrita_20210529_001327/assets
{'modelNames': ['Modelo001-Papafrita'], 'modelTrainingData': {'Modelo001-Papafrita': {'history': {'accuracy': [], 'loss': [], 'val_accuracy': [], 'val_loss': []}, 'epochs': 0}}}

```
1  %tensorflow_version 2.x
2  import tensorflow as tf
3  import keras
4  #@markdown ##Nombra el Modelo actual
5  model_name = "Modelo002-ReyLeonsio" #@param
6  model_storage = route

```

Nombra el Modelo actual

model_name: "Modelo001-Papafrita"

Nombra el Modelo actual

model_name: "Modelo002-ReyLeonsio"


```
6 model_storage = route
7 with tf.device('/device:GPU:0'):
8     model = tf.keras.models.Sequential(name=model_name)
9     model.add(tf.keras.layers.Conv2D(32, kernel_size=(3, 3),
10         activation='relu',
11         input_shape=(150, 150, 3)))
12     model.add(tf.keras.layers.MaxPooling2D(pool_size=(2, 2)))
13     model.add(tf.keras.layers.Conv2D(64, (3, 3), activation='relu'))
14     model.add(tf.keras.layers.MaxPooling2D(pool_size=(2, 2)))
15     model.add(tf.keras.layers.Conv2D(64, (3, 3), activation='relu'))
16     model.add(tf.keras.layers.MaxPooling2D(pool_size=(2, 2)))
17     model.add(tf.keras.layers.Dropout(0.25))
18     model.add(tf.keras.layers.Flatten())
19     model.add(tf.keras.layers.Dense(128, activation='relu'))
20     model.add(tf.keras.layers.Dropout(0.5))
21     model.add(tf.keras.layers.Dense(9, activation='softmax'))
22
23     model.compile(loss=keras.losses.categorical_crossentropy,
24         optimizer=keras.optimizers.Adadelta(),
25         metrics=['accuracy'])
26     model.build( input_shape =(150, 150, 3))
27
28     model.summary()
29
30     save_model(model_storage, model)
```

Model: "Modelo002-ReyLeonsio"

Layer (type)	Output Shape	Param #
=====		
conv2d_18 (Conv2D)	(None, 148, 148, 32)	896
max_pooling2d_18 (MaxPooling)	(None, 74, 74, 32)	0
conv2d_19 (Conv2D)	(None, 72, 72, 64)	18496
max_pooling2d_19 (MaxPooling)	(None, 36, 36, 64)	0
conv2d_20 (Conv2D)	(None, 34, 34, 64)	36928
max_pooling2d_20 (MaxPooling)	(None, 17, 17, 64)	0
dropout_14 (Dropout)	(None, 17, 17, 64)	0
flatten_7 (Flatten)	(None, 18496)	0
dense_14 (Dense)	(None, 128)	2367616
dropout_15 (Dropout)	(None, 128)	0
dense_15 (Dense)	(None, 9)	1161
=====		
Total params: 2,425,097		
Trainable params: 2,425,097		
Non-trainable params: 0		

INFO:tensorflow:Assets written to: gdrive/MyDrive/Colab Notebooks/models/Modelo002-ReyLeonsio_20210529_001329/assets
{'modelNames': ['Modelo001-Papafrita', 'Modelo002-ReyLeonsio'], 'modelTrainingData': {'Modelo001-Papafrita': {'history': {'accuracy': [], 'loss': [], 'val_accuracy': [], 'val_loss': []},




```
1 %tensorflow_version 2.x
2 import tensorflow as tf
3 import keras
4 #@markdown ##Crear modelo
5 model_name = "Modelo003-JuanSinMiedo" #@param
6 model_storage = route
7 with tf.device('/device:GPU:0'):
8     model = tf.keras.models.Sequential(name=model_name)
9     model.add(tf.keras.layers.Conv2D(32, kernel_size=(3, 3),
10         activation='relu',
11         input_shape=(150, 150, 3)))
12     model.add(tf.keras.layers.MaxPooling2D(pool_size=(2, 2)))
13     model.add(tf.keras.layers.Conv2D(128, (3, 3), activation='relu'))
14     model.add(tf.keras.layers.MaxPooling2D(pool_size=(2, 2)))
15     model.add(tf.keras.layers.Dropout(0.25))
16     model.add(tf.keras.layers.Flatten())
17     model.add(tf.keras.layers.Dense(128, activation='relu'))
18     model.add(tf.keras.layers.Dropout(0.5))
19     model.add(tf.keras.layers.Dense(9, activation='softmax'))
20
21     model.compile(loss=keras.losses.categorical_crossentropy,
22         optimizer=keras.optimizers.Adadelta(),
23         metrics=['accuracy'])
24     model.build( input_shape =(150, 150, 3))
25
26     model.summary()
27
28     save_model(model_storage, model)
```

Model: "Modelo003-JuanSinMiedo"

Layer (type)	Output Shape	Param #
=====		
conv2d_21 (Conv2D)	(None, 148, 148, 32)	896
max_pooling2d_21 (MaxPooling)	(None, 74, 74, 32)	0
conv2d_22 (Conv2D)	(None, 72, 72, 128)	36992
max_pooling2d_22 (MaxPooling)	(None, 36, 36, 128)	0
dropout_16 (Dropout)	(None, 36, 36, 128)	0
flatten_8 (Flatten)	(None, 165888)	0
dense_16 (Dense)	(None, 128)	21233792
dropout_17 (Dropout)	(None, 128)	0
dense_17 (Dense)	(None, 9)	1161
=====		
Total params: 21,272,841		
Trainable params: 21,272,841		
Non-trainable params: 0		

INFO:tensorflow:Assets written to: gdrive/MyDrive/Colab Notebooks/models/Modelo003-JuanSinMiedo_20210529_001334/assets
{'modelNames': ['Modelo001-Papafrita', 'Modelo002-ReyLeonsio', 'Modelo003-JuanSinMiedo'], 'modelTrainingData': {'Modelo001-Papafrita': {'history': {'accuracy': [], 'loss': [], 'val_accura



```
1 import tensorflow as tf
2 import keras
3
4 #@markdown ##Crear modelo
5 model_name = "Modelo004-Calamardo" #@param
6 model_storage = route
7 with tf.device('/device:GPU:0'):
8     model = tf.keras.models.Sequential(name=model_name)
9     model.add(tf.keras.layers.Conv2D(32, kernel_size=(3, 3),
10         activation='sigmoid',
11         input_shape=(150, 150, 3)))
12     model.add(tf.keras.layers.MaxPooling2D(pool_size=(2, 2)))
13     model.add(tf.keras.layers.Conv2D(128, (3, 3), activation='relu'))
14     model.add(tf.keras.layers.MaxPooling2D(pool_size=(2, 2)))
15     model.add(tf.keras.layers.Dropout(0.25))
16     model.add(tf.keras.layers.Flatten())
17     model.add(tf.keras.layers.Dense(256, activation='relu'))
18     model.add(tf.keras.layers.Dropout(0.5))
19     model.add(tf.keras.layers.Dense(9, activation='softmax'))
20
21     model.compile(loss=keras.losses.categorical_crossentropy,
22         optimizer=keras.optimizers.Adadelta(),
23         metrics=['accuracy'])
24     model.build( input_shape =(150, 150, 3))
25
26     model.summary()
27
28     save_model(model_storage, model)
```

Model: "Modelo004-Calamardo"

Layer (type)	Output Shape	Param #
=====		
conv2d_23 (Conv2D)	(None, 148, 148, 32)	896

max_pooling2d_23 (MaxPooling)	(None, 74, 74, 32)	0

conv2d_24 (Conv2D)	(None, 72, 72, 128)	36992

max_pooling2d_24 (MaxPooling)	(None, 36, 36, 128)	0

dropout_18 (Dropout)	(None, 36, 36, 128)	0


flatten_9 (Flatten)	(None, 165888)	0

dense_18 (Dense)	(None, 256)	42467584

dropout_19 (Dropout)	(None, 256)	0

dense_19 (Dense)	(None, 9)	2313
=====		
Total params: 42,507,785		
Trainable params: 42,507,785		
Non-trainable params: 0		

INFO:tensorflow:Assets written to: gdrive/MyDrive/Colab Notebooks/models/Modelo004-Calamardo_20210529_001340/assets
{'modelNames': ['Modelo001-Papafrita', 'Modelo002-ReyLeonsio', 'Modelo003-JuanSinMiedo', 'Modelo004-Calamardo'], 'modelTrainingData': {'Modelo001-Papafrita': {'history': {'accuracy': [],



```
1 %tensorflow_version 2.x
2 import tensorflow as tf
3 import keras
4 #@markdown ##Crear modelo
5 model_name = "Modelo005-VendoOpelCorsa" #@param
6 model_storage = route
7 with tf.device('/device:GPU:0'):
8     model = tf.keras.models.Sequential(name=model_name)
9     model.add(tf.keras.layers.Conv2D(32, kernel_size=(3, 3),
10         activation='relu',
11         input_shape=(150, 150, 3)))
12     model.add(tf.keras.layers.MaxPooling2D(pool_size=(2, 2)))
13     model.add(tf.keras.layers.Conv2D(128, (3, 3), activation='relu'))
14     model.add(tf.keras.layers.MaxPooling2D(pool_size=(2, 2)))
15     model.add(tf.keras.layers.Dropout(0.25))
16     model.add(tf.keras.layers.Flatten())
17     model.add(tf.keras.layers.Dense(128, activation='relu'))
18     model.add(tf.keras.layers.Dropout(0.5))
19     model.add(tf.keras.layers.Dense(9, activation='softmax'))
20
21     model.compile(loss=keras.losses.categorical_crossentropy,
22         optimizer=keras.optimizers.SGD(),
23         metrics=['accuracy'])
24     model.build( input_shape =(150, 150, 3))
25
26     model.summary()
27
28     save_model(model_storage, model)
```

Model: "Modelo005-VendoOpelCorsa"

Layer (type)	Output Shape	Param #
=====		
conv2d_25 (Conv2D)	(None, 148, 148, 32)	896

max_pooling2d_25 (MaxPooling)	(None, 74, 74, 32)	0

conv2d_26 (Conv2D)	(None, 72, 72, 128)	36992

max_pooling2d_26 (MaxPooling)	(None, 36, 36, 128)	0

dropout_20 (Dropout)	(None, 36, 36, 128)	0


flatten_10 (Flatten)	(None, 165888)	0

dense_20 (Dense)	(None, 128)	21233792

dropout_21 (Dropout)	(None, 128)	0

dense_21 (Dense)	(None, 9)	1161
=====		
Total params: 21,272,841		
Trainable params: 21,272,841		
Non-trainable params: 0		

INFO:tensorflow:Assets written to: gdrive/MyDrive/Colab Notebooks/models/Modelo005-VendoOpelCorsa_20210529_001343/assets
{'modelNames': ['Modelo001-Papafrita', 'Modelo002-ReyLeonsio', 'Modelo003-JuanSinMiedo', 'Modelo004-Calamardo', 'Modelo005-VendoOpelCorsa'], 'modelTrainingData': {'Modelo001-Papafrita': {



Diferencia entre modelos

Crear modelo

model_name: "Modelo004-Calamardo"

Crear modelo

model_name: "Modelo005-VendoOpelCorsa"

	Conv2D	MaxPooling2D	Conv2D	MaxPooling2D	Conv2D	MaxPooling2D	Dropout	Flatten	Dense	Dropout	Dense
Papafrita	32; 3x3; relu	3x3	64; 5x5; relu	3x3	64; 3x3; relu	2x2	0.25	X	128; relu	0.5	9; softmax
ReyLeonsio	32; 3x3; relu	2x2	64; 3x3; relu	2x2	64; 3x3; relu	2x2	0.25	X	128; relu	0.5	9; softmax
JuanSinMiedo	32; 3x3; relu	2x2	128; 3x3; relu	2x2			0.25	x	128; relu	0.5	9; softmax
Calamardo	32; 3x3; sigmoid	2x2	128; 3x3; relu	2x2			0.25	X	256; relu	0.5	9; softmax
VendoOpelCorsa	32; 3x3; relu	2x2	128; 3x3; relu	2x2			0.25	X	128; relu	0.5	9; softmax

▼ Entrenamiento de modelos

Agregamos *X* épocas de entrenamiento (epochs) a cada uno de los modelos. Por defecto se escogerán a todos los modelos para entrenarlos, sin embargo, hemos desarrollado una estrategia para excluir a ciertos modelos que se necesitarán especificar por su nombre (exclude_from_training, en forma de array de Strings).

```
1  #@markdown ##Entrenamiento de los modelos creados
2
3  %tensorflow_version 2.x
4  import tensorflow as tf
5  from keras.preprocessing.image import ImageDataGenerator
6  from keras.models import Sequential
7  from keras.layers import Dense, Dropout
8  from keras.optimizers import RMSprop
9  from keras.layers import Dense, Dropout, Flatten
10 from keras.layers import Conv2D, MaxPooling2D
11
12 from keras.callbacks import EarlyStopping
13 from keras import backend as K
14 import keras
15 from time import time
16
17 # DATA SOURCE -----
18
19 batch_size = 20
20
21 train_data_dir = '/content/datasets/uncompressed/train/'
22 validation_data_dir = '/content/datasets/uncompressed/test/'
23 model_storage = route
24 train_datagen = ImageDataGenerator(
25     rescale=1./255,
26     rotation_range=15,
27     zoom_range=0.1)
28
29 test_datagen = ImageDataGenerator(rescale=1./255)
30
31 train_generator = train_datagen.flow_from_directory(
32     train_data_dir,
33     target_size=(150, 150),
34     batch_size=batch_size,
35     class_mode='categorical')
36
37 validation_generator = test_datagen.flow_from_directory(
38     validation_data_dir,
39     target_size=(150, 150),
40     batch_size=batch_size,
41     class_mode='categorical')
42
43 # MODEL -----
44 loaded_models, config = load_models(tf)
45
46 # TRAINING -----
47 epochs = 1#@param
48 exclude_from_training = ['Modelo001-Papafrita', 'Modelo002-ReyLeonsio', 'Modelo003-JuanS:
49 for model_str in loaded_models:
50     model = loaded_models[model_str]
51
52     if model_str in exclude_from_training:
53         continue
54     model.summary()
55
56     model_history = config['modelTrainingData'][model_str]
57     H = model.fit(
58         train_generator,
59         epochs=epochs,
60         validation_data=validation_generator
61     )
62
63 # SAVING -----
64     model_history['epochs'] += epochs
65     model_history['history']['accuracy'].extend( H.history["accuracy"] )
66     model_history['history']['val_accuracy'].extend( H.history["val_accuracy"] )
67     model_history['history']['loss'].extend( H.history["loss"] )
68     model_history['history']['val_loss'].extend( H.history["val_loss"] )
69
70     save_model(model_storage,model )
71     save_config_to_json(config)
```

Found 1203 images belonging to 9 classes.
Found 274 images belonging to 9 classes.
Model: "Modelo005-VendoOpelCorsa"

Layer (type)	Output Shape	Param #
conv2d (Conv2D)	(None, 148, 148, 32)	896
max_pooling2d (MaxPooling2D)	(None, 74, 74, 32)	0
conv2d_1 (Conv2D)	(None, 72, 72, 128)	36992
max_pooling2d_1 (MaxPooling2	(None, 36, 36, 128)	0
dropout (Dropout)	(None, 36, 36, 128)	0
flatten (Flatten)	(None, 165888)	0
dense (Dense)	(None, 128)	21233792
dropout_1 (Dropout)	(None, 128)	0
dense_1 (Dense)	(None, 9)	1161
Total params: 21,272,841		

Entrenamiento de los modelos creados

epochs: 1

exclude_from_training: ['Modelo001-Papafrita', 'Modelo002-ReyLeonsio', 'Modelo003-JuanSir

Trainable params: 21,272,841
Non-trainable params: 0

61/61 [=====] - 11s 170ms/step - loss: 0.1610 - accuracy: 0.9418 - val_loss: 3.6412 - val_accuracy: 0.3285
INFO:tensorflow:Assets written to: gdrive/MyDrive/ColabNotebooks/models/Modelo005-VendoOpelCorsa_20210602_111532/assets





▼ Análisis de resultados de forma gráfica

Creamos cuatro gráficas que ilustran la progresión de los diferentes modelos utilizando las métricas *accuracy* y *loss* tanto de entrenamiento como de validación.

```
1 import matplotlib.pyplot as plt
2 import numpy as np
3
4 config = load_configuration_json()
5 plt.style.use("ggplot")
6
7 plt.figure()
8 for model_str in config['modelNames']:
9     h = config['modelTrainingData'][model_str]
10    plt.plot(np.arange(0, h['epochs']), h['history']['accuracy'], label=model_str)
11    plt.title("Training Accuracy by model")
12    plt.xlabel("Epoch #")
13    plt.ylabel("Accuracy")
14    plt.legend(loc="best")
15    plt.savefig("accuracy.png")
16
17 plt.figure()
18 for model_str in config['modelNames']:
19     h = config['modelTrainingData'][model_str]
20    plt.plot(np.arange(0, h['epochs']), h['history']['val_accuracy'], label=model_str)
21    plt.title("Validation Accuracy by model")
22    plt.xlabel("Epoch #")
23    plt.ylabel("Accuracy")
24    plt.legend(loc="best")
25    plt.savefig("val_accuracy.png")
26
27 plt.figure()
28 for model_str in config['modelNames']:
29     h = config['modelTrainingData'][model_str]
30    plt.plot(np.arange(0, h['epochs']), h['history']['loss'], label=model_str)
31    plt.title("Training Loss by model")
32    plt.xlabel("Epoch #")
33    plt.ylabel("Loss")
34    plt.legend(loc="best")
35    plt.savefig("loss.png")
36
37 plt.figure()
38 for model_str in config['modelNames']:
39     h = config['modelTrainingData'][model_str]
40    plt.plot(np.arange(0, h['epochs']), h['history']['val_loss'], label=model_str)
41    plt.title("Validation Loss by model")
42    plt.xlabel("Epoch #")
43    plt.ylabel("Loss")
44    plt.legend(loc="best")
45    plt.savefig("val_loss.png")
```



Conclusiones



De las gráficas anteriores interpretamos que, a pesar de que el modelo VendoOpelCorsa identifica muy bien las imágenes de entrenamiento, no es capaz de generalizar correctamente a la hora de ver imágenes que no ha visto anteriormente. También observamos el impacto del algoritmo optimizador utilizado (Adadelta para JuanSinMiedo, SGD para VendoOpelCorsa), donde aunque el GSD parece el más prometedor al principio, Adadelta termina obteniendo el mejor resultado. En vista de los resultados, a partir de aquí lo conveniente sería iterar sobre el modelo JuanSinMiedo para el diseño del siguiente modelo.

Matriz de confusión

En este apartado mostramos la matriz de confusión de uno de nuestros modelos. Para especificar el modelo, éste se debe introducir de manera manual.

```
1  modelName = 'Modelo005-VendoOpelCorsa' #@param ['Modelo001-Papafrita', 'Modelo002-ReyLeo
2  mostrarPredicciones = True #@param {type:"boolean"}
3  matrix_as_text = True #@param {type:"boolean"}
4  model = loaded_models[modelName]
5
6  validation_generator = test_datagen.flow_from_directory(
7      validation_data_dir,
8      target_size=(150, 150),
9      batch_size=batch_size,
10     class_mode='categorical',
11     shuffle=False)
12  predictions = model.predict(validation_generator)
13
14  import numpy as np
15  y_pred = np.argmax(predictions, axis=1)
16  y_real = validation_generator.classes
17  if mostrarPredicciones:
18      print("Valores de predicción:\n", y_pred)
19      print("Valores reales:\n", y_real)
20
21  from sklearn.metrics import confusion_matrix
22  conf_matrix = confusion_matrix(y_real,y_pred)
23  if matrix_as_text:
24      print("Matriz de confusión:\n", conf_matrix)
25
26  import seaborn as sns
27  import matplotlib.pyplot as plt
28
29  ax= plt.subplot()
30
```

modelName:

mostrarPredicciones: ☒

matrix_as_text: ☒

```
31 g = sns.heatmap(conf_matrix, annot=True, fmt='g', ax=ax); #annot=True to annotate cells,
32 g.set_yticklabels(g.get_yticklabels(), rotation = 0, fontsize = 8)
33 g.set_xticklabels(g.get_xticklabels(), rotation = 80, fontsize = 8,)
34
35 labels =!ls datasets/uncompressed/test/* -d
36 trimmed_labels =[]
37 for label in labels:
38     trimmed_labels.append('-'.join(label.split('-')[1:]))
39
40 ax.set_xlabel('Predicted labels');ax.set_ylabel('True labels');
41 ax.set_title('Confusion Matrix: ' + modelName);
42 ax.xaxis.set_ticklabels(trimmed_labels);
43 ax.yaxis.set_ticklabels(trimmed_labels);
```

Found 274 images belonging to 9 classes.

Valores de predicción:
[8 0 1 0 7 5 7 3 0 0 3 8 0 4 0 0 0 8 3 7 3 8 2 2 0 0 1 3 4 4 3 0 0 8 7 3 2
0 8 8 8 0 7 1 6 5 4 4 1 3 1 0 3 4 6 3 3 4 2 8 3 1 8 0 4 7 3 6 3 8 1 3 1 4
3 2 2 2 2 3 4 2 8 0 8 3 2 2 2 6 8 2 2 8 8 8 8 3 3 3 2 8 2 4 1 4 1 0 2 1 4
1 3 3 7 3 3 4 0 3 3 3 3 3 4 3 5 1 7 8 5 2 5 3 8 0 2 7 3 3 5 7 6 0 1 3 3 4
3 1 1 4 3 4 3 8 3 3 5 5 5 7 1 7 5 5 6 5 2 5 6 0 6 5 0 5 8 5 4 5 6 5 5 7 0
1 8 1 3 6 3 1 7 6 3 5 2 5 8 0 8 2 7 7 3 6 3 7 7 3 8 0 8 3 1 0 7 7 1 7 7 1
8 6 3 0 8 7 2 0 7 4 3 8 4 7 3 7 7 8 8 8 0 6 4 2 8 6 7 8 8 3 8 7 6 8 8 0 8
8 4 1 7 8 8 0 8 8 7 8 2 7 7 8]

Valores reales:
[0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0
0 0 0 0 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1
2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 3 3 3 3 3 3 3
3 3 3 3 3 3 3 3 3 3 3 3 3 3 3 4 4 4 4 4 4 4 4 4 4 4 4 4 4 4 4 4 4 4 4
4 4 4 4 4 4 4 4 4 4 4 4 4 5 5 5 5 5 5 5 5 5 5 5 5 5 5 5 5 5 5 5 5 5 6
6 6 6 6 6 6 6 6 6 6 6 6 6 6 6 6 6 6 6 6 6 6 6 6 6 6 6 6 6 6 6 6 6 6 6
7 7 7 7 7 7 7 7 7 7 7 7 7 7 7 7 7 8 8 8 8 8 8 8 8 8 8 8 8 8 8 8 8 8 8
8 8 8 8 8 8 8 8 8 8 8 8 8 8 8 8 8]

Matriz de confusión:
[[13 2 3 7 3 1 0 4 8]
[3 6 1 8 6 1 3 2 3]
[1 0 12 6 1 0 1 0 8]
[2 4 1 10 5 0 0 1 0]
[2 4 2 10 3 5 1 3 3]
[2 1 1 0 1 12 4 3 1]
[2 3 2 5 0 2 3 5 3]
[4 3 1 5 2 0 1 9 5]
[3 1 2 1 2 0 3 6 17]]

